

Phát hiện Văn bản do Máy Tạo Ra trên Mạng Xã Hội Đa Ngôn Ngữ: Nghiên cứu So sánh Bốn Phương pháp trên Phần Cứng Phổ Thông

Hoàng Nguyễn Anh Khoa¹

¹Trường Đại học Công nghệ Thông tin
Đại học Quốc gia TP. Hồ Chí Minh, Việt Nam
Giảng viên hướng dẫn: Lưu Thanh Sơn

Trường Đại học Công nghệ Thông tin,
Đại học Quốc gia TP. Hồ Chí Minh, Việt Nam
23520736@gm.uit.edu.vn

Abstract. Sự phổ biến của các mô hình ngôn ngữ lớn (LLM) đã tạo ra làn sóng văn bản do máy tạo ra (MGT) tràn lan trên các nền tảng mạng xã hội đa ngôn ngữ, đặt ra thách thức cấp thiết về phát hiện và kiểm duyệt nội dung. Các phương pháp hiện tại chủ yếu được thiết kế cho tiếng Anh và đòi hỏi phần cứng GPU cao cấp, gây khó khăn cho việc triển khai thực tế. Bài báo này trình bày một nghiên cứu so sánh hệ thống bốn phương pháp phát hiện MGT trên dữ liệu mạng xã hội đa ngôn ngữ gồm bốn ngôn ngữ: tiếng Anh (EN), tiếng Việt (VI), tiếng Trung (ZH) và tiếng Ả Rập (AR). Chúng tôi xây dựng một bộ dữ liệu cân bằng gồm 15.986 bài đăng từ các corpus MXH thực tế, sau đó lần lượt đánh giá: (1) bộ phát hiện tiền huấn luyện zero-shot, (2) tinh chỉnh XLM-RoBERTa đa ngôn ngữ, (3) phát hiện thống kê dựa trên Perplexity, và (4) học chuyển giao đa ngôn ngữ (leave-one-language-out). Phương pháp tinh chỉnh XLM-RoBERTa đạt độ chính xác trung bình **81,4%** trên cả bốn ngôn ngữ, được huấn luyện trong 7,5 phút trên GPU T4 với chi phí ước tính **\$1,50**. Kết quả chứng minh rằng phát hiện MGT đa ngôn ngữ chất lượng cao hoàn toàn khả thi trên phần cứng phổ thông, đồng thời cho thấy học chuyển giao liên ngôn ngữ là chưa đủ, đặc biệt với tiếng Việt ($F1 = 0,134$ khi thiếu dữ liệu huấn luyện).

Keywords: Phát hiện văn bản do máy tạo · Mạng xã hội đa ngôn ngữ · XLM-RoBERTa · Perplexity · Tiếng Việt · Tiếng Trung · Tiếng Ả Rập

1 Giới Thiệu

Sự bùng nổ của các mô hình ngôn ngữ lớn (LLM) như GPT-4, LLaMA và Qwen trong những năm gần đây đã tạo ra khả năng tạo văn bản tự động với chất lượng gần tương đương con người [2,11]. Trên các nền tảng mạng xã hội (MXH) đa ngôn ngữ, điều này tạo ra rủi ro nghiêm trọng: nội dung do máy tạo ra

(Machine-Generated Text — MGT) có thể được phát tán quy mô lớn nhằm mục đích gây nhiễu thông tin, thao túng dư luận, hoặc tự động hóa spam [12].

Hầu hết các bộ phát hiện MGT hiện nay được xây dựng và đánh giá chủ yếu trên tiếng Anh [10,7]. Khi áp dụng sang ngôn ngữ khác, hiệu năng sụt giảm nghiêm trọng do thiên lệch ngôn ngữ trong quá trình huấn luyện. Ngoài ra, nhiều phương pháp tiên tiến đòi hỏi GPU A100 (40–80 GB VRAM), xa tầm tay của hầu hết nhà nghiên cứu và tổ chức tại các nước đang phát triển.

Bài báo này đề xuất và đánh giá ba phương pháp phát hiện MGT trên dữ liệu MXH đa ngôn ngữ, với các đóng góp chính sau:

1. **Bộ dữ liệu đa ngôn ngữ:** Xây dựng MultiSocial-4L, bộ dữ liệu gồm 15.985 bài đăng MXH cân bằng (human/machine) trên bốn ngôn ngữ EN, VI, ZH, AR, được tạo từ các corpus thực tế và các LLM hiện đại.
2. **Đánh giá hệ thống:** So sánh toàn diện bốn phương pháp — zero-shot với bộ phát hiện tiền huấn luyện (RoBERTa), tinh chỉnh mô hình đa ngôn ngữ (XLM-RoBERTa), phát hiện thống kê dựa trên Perplexity (Qwen2.5-1.5B), và học chuyển giao đa ngôn ngữ (leave-one-language-out) — trên cùng một bộ dữ liệu.
3. **Khả thi trên phần cứng phổ thông:** Toàn bộ pipeline thực nghiệm được thiết kế và chạy thành công trên Google Colab T4 (16 GB VRAM), với tổng chi phí API ước tính \$1,50.

Phần còn lại của bài báo được tổ chức như sau: Phần 2 điểm lại các công trình liên quan; Phần 3 mô tả quá trình xây dựng bộ dữ liệu; Phần 4 trình bày bốn phương pháp thực nghiệm; Phần 5 báo cáo và phân tích kết quả; Phần 6 tổng kết và đề xuất hướng nghiên cứu tiếp theo.

2 Công Trình Liên Quan

Phát hiện MGT đơn ngôn ngữ

Solaiman et al. [10] giới thiệu bộ phát hiện GPT-2 đầu tiên dựa trên RoBERTa, được fine-tuned trên văn bản do GPT-2 tạo ra. Dù đạt độ chính xác cao trên tiếng Anh, mô hình này không tổng quát hóa sang ngôn ngữ khác do thiếu dữ liệu huấn luyện đa ngôn ngữ. Mitchell et al. [7] đề xuất DetectGPT, một phương pháp zero-shot dựa trên độ cong của hàm log-probability, không cần nhân huấn luyện nhưng đòi hỏi LLM ở mức trắng hộp (white-box).

Phát hiện MGT đa ngôn ngữ

Guo et al. [5] nghiên cứu phát hiện MGT trên tiếng Trung, cho thấy các mô hình tiếng Anh thất bại hoàn toàn khi chuyển sang ngữ cảnh MXH Trung Quốc (Weibo). Lý giải được đưa ra là đặc tính bài đăng ngắn và ngữ nghĩa dày đặc ở cấp ký tự. Các nghiên cứu về tiếng Việt [8] và tiếng Ả Rập [1] cho thấy tương tự: hiện tượng “Teencode” trong tiếng Việt (viết tắt có chủ đích, bỏ dấu) và cấu trúc hình thái phong phú trong tiếng Ả Rập gây khó khăn đặc thù cho các detector.

Phát hiện dựa trên Perplexity

Hans et al. [6] và Equi et al. [4] cho thấy văn bản do LLM tạo ra thường có perplexity (PPL) thấp hơn so với văn bản con người khi được đánh giá bởi cùng một LLM, do phân phối của chúng khớp với phân phối huấn luyện. Tuy nhiên, phương pháp này nhạy cảm với nhiều ngôn ngữ — một đặc điểm phổ biến trong văn bản MXH không chính thức.

Bài báo này bổ sung vào khoảng trống nghiên cứu bằng cách (i) xây dựng bộ dữ liệu MXH thực tế cho cả bốn ngôn ngữ EN/VI/ZH/AR, (ii) đánh giá đồng thời và có hệ thống ba họ phương pháp, và (iii) chứng minh tính khả thi trên phần cứng GPU tiêu dùng (T4).

3 Xây Dựng Bộ Dữ Liệu

3.1 Dữ Liệu Nguồn (Văn Bản Con Người)

Để phản ánh thực tế đa dạng của mạng xã hội, chúng tôi chọn bốn corpus MXH thực tế, mỗi corpus đại diện cho một ngôn ngữ và nền tảng khác nhau (Bảng 1).

Table 1: Corpus dữ liệu nguồn (văn bản con người)

Ngôn ngữ Corpus		Nền tảng	Số bài
EN	Sentiment140	Twitter	2.000
VI	VSmec	Facebook/MXH VN	2.000
ZH	Weibo Senti 100K	Weibo	2.000
AR	AJGT	Twitter	2.000

Từ mỗi corpus, chúng tôi lấy mẫu ngẫu nhiên có phân tầng 2.000 bài đăng, đảm bảo đa dạng về chủ đề và phong cách. Các bài đăng trùng lặp và rỗng được loại bỏ trước khi tạo văn bản máy.

3.2 Tạo Văn Bản Máy (Machine Text)

Mỗi bài đăng con người được paraphrase 1:1 bởi một LLM phù hợp với ngôn ngữ đó thông qua API (Bảng 2). Chúng tôi sử dụng prompt dạng paraphrase thay vì generation thuần túy nhằm giữ nguyên chủ đề và ngữ cảnh, đồng thời tạo ra cặp (human, machine) có nội dung tương đồng — kịch bản thực tế nhất của MGT trên MXH.

Các bài đăng không được xử lý thành công (lỗi API, phản hồi rỗng hoặc quá ngắn) bị loại bỏ. Đối với tiếng Việt, 7 bài bị loại do lỗi API và vi phạm chính sách nội dung, dẫn đến 3.986 bài thay vì 4.000.

Table 2: LLM được sử dụng để tạo văn bản máy

Ngôn ngữ Mô hình		Nhà cung cấp API
EN	LLaMA 3.1-8B-Instant	Groq API
VI	GPT-OSS 20B	NVIDIA NIM
ZH	Qwen3-80B-A3B-Instruct	NVIDIA NIM
AR	LLaMA 4 Maverick 17B	NVIDIA NIM

Table 3: Thống kê bộ dữ liệu MultiSocial-4L

Ngôn ngữ	Tổng	Train	Test	Ghi chú
EN	4.000	3.200	800	
VI	3.986	3.189	797	7 bài bị loại
ZH	4.000	3.200	800	
AR	4.000	3.200	800	
Tổng	15.986	12.789	3.197	

3.3 Thống Kê Bộ Dữ Liệu Cuối

Bộ dữ liệu cuối gồm **15.986 bài đăng** (7.993 human / 7.993 machine), được phân chia 80/20 theo phân tầng ngôn ngữ và nhân (Bảng 3).

Mỗi bản ghi gồm các trường: `text`, `label` (0=human, 1=machine), `language`, `length`, `source` và `split`. Dữ liệu được cân bằng hoàn toàn (50% human / 50% machine) theo từng ngôn ngữ.

4 Phương Pháp

Chúng tôi đánh giá bốn phương pháp theo thứ tự tăng dần về độ phức tạp và chi phí tính toán: (1) zero-shot với bộ phát hiện tiền huấn luyện, (2) tinh chỉnh mô hình đa ngôn ngữ có giám sát, (3) phát hiện thống kê zero-shot dựa trên perplexity, và (4) học chuyển giao đa ngôn ngữ (leave-one-language-out).

4.1 Phương Pháp 1: Baseline Zero-Shot (RoBERTa)

Chúng tôi áp dụng trực tiếp mô hình `roberta-base-openai-detector` [10] — được tiền huấn luyện để phân biệt văn bản GPT-2 với văn bản con người tiếng Anh — lên toàn bộ bộ kiểm tra đa ngôn ngữ mà không có bất kỳ thích nghi nào. Nhân dự đoán được xác định bằng ngưỡng $\tau = 0.5$ trên điểm sigmoid của logit:

$$\hat{y} = \mathbf{1}[\sigma(z_{\text{machine}} - z_{\text{human}}) \geq 0.5]$$

Đây là kịch bản “worst-case” phản ánh thực tế thường gặp khi triển khai một detector tiếng Anh cho dữ liệu đa ngôn ngữ.

4.2 Phương Pháp 2: Tinh Chỉnh XLM-RoBERTa

Chúng tôi tinh chỉnh `xlm-roberta-base` [3] (278M tham số, được tiền huấn luyện trên 100 ngôn ngữ) theo bài toán phân loại nhị phân (human/machine) trên toàn bộ 12.789 mẫu huấn luyện đa ngôn ngữ. Các siêu tham số chính:

- Số epoch: 3; Learning rate: 2×10^{-5} ; Batch size: 16
- Max sequence length: 256 tokens; Precision: fp16
- Fallback OOM: batch size 8 + gradient accumulation 2
- Metric tối ưu: Macro-F1

Mô hình được huấn luyện trên Google Colab T4 (16 GB VRAM). Tổng thời gian huấn luyện: **7 phút 30 giây** (2.400 bước). Checkpoint tốt nhất (epoch 3) được lưu lại để đánh giá.

4.3 Phương Pháp 3: Phát Hiện Thống Kê Dựa Trên Perplexity

Dựa trên giả thuyết rằng LLM gán perplexity thấp hơn cho văn bản do máy tạo ra (vì nó khớp với phân phối ngôn ngữ của mô hình), chúng tôi sử dụng Qwen/Qwen2.5-1.5B [9] để tính PPL của từng bài đăng:

$$\text{PPL}(x) = \exp\left(\frac{1}{T} \sum_{t=1}^T \mathcal{L}(x_t \mid x_{<t})\right)$$

trong đó $\mathcal{L}$ là cross-entropy loss và T là số token. Điểm phát hiện được định nghĩa là $s = -\text{PPL}(x)$ (điểm cao hơn $\Rightarrow$ khả năng do máy tạo cao hơn). Phương pháp này hoàn toàn zero-shot, không cần nhãn. Metric đánh giá: AUC-ROC (không phụ thuộc ngưỡng). Cấu hình: `bfloat16`, `device_map='auto'`, `max_length=512`, `batch=8`.

4.4 Phương Pháp 4: Học Chuyển Giao (Transfer Learning)

Để đánh giá khả năng tổng quát hóa liên ngôn ngữ, chúng tôi thực hiện thí nghiệm *leave-one-language-out*: với mỗi ngôn ngữ, huấn luyện XLM-RoBERTa trên ba ngôn ngữ còn lại và kiểm tra trên ngôn ngữ bị giữ lại. Mô hình được khởi tạo mới cho mỗi thí nghiệm. Các siêu tham số chính:

- Số epoch: 5; Learning rate: 2×10^{-5} ; Batch size: 16
- Max sequence length: 512 tokens; Weight decay: 0,01
- Warmup ratio: 0,1; Early stopping patience: 2
- Precision: fp16; Train/val split: 80/20

Quy trình này mô phỏng kịch bản thực tế khi một ngôn ngữ mới xuất hiện mà không có dữ liệu huấn luyện, buộc hệ thống phải dựa vào kiến thức từ các ngôn ngữ khác.

5 Kết Quả và Thảo Luận

5.1 Kết Quả Baseline Zero-Shot

Bảng 4 trình bày kết quả của `roberta-base-openai-detector` trên bộ kiểm tra. Chỉ có tiếng Anh vượt mức ngẫu nhiên (64,1%), trong khi ba ngôn ngữ còn lại đều ở mức 48–51% — sát ngưỡng phân loại ngẫu nhiên (50%). Đặc biệt, tiếng Ả Rập đạt Macro-F1 chỉ **0,336**, cho thấy mô hình đang phân loại sai hệ thống: dự đoán “machine” cho văn bản human và ngược lại.

Table 4: Kết quả Phương pháp 1: Baseline Zero-Shot (`roberta-base-openai-detector`)

Ngôn ngữ	Accuracy	Macro-F1	N test	Nhận xét
EN	64,1%	0,623	800	Vượt ngẫu nhiên
VI	50,7%	0,493	797	Gần ngẫu nhiên
ZH	47,6%	0,407	800	Dưới ngẫu nhiên
AR	48,3%	0,336	800	Phân loại sai hệ thống

Kết quả này xác nhận **thiên lệch Anh ngữ nghiêm trọng** trong bộ phát hiện tiền huấn luyện: triển khai trực tiếp cho dữ liệu đa ngôn ngữ không chỉ kém hiệu quả mà còn có thể gây hại hơn không dùng gì. Đường cong ROC của cả bốn ngôn ngữ được thể hiện tại Hình 1.

5.2 Kết Quả Tinh Chỉnh XLM-RoBERTa

Sau khi tinh chỉnh trên 12.789 mẫu đa ngôn ngữ, hiệu năng cải thiện đáng kể trên tất cả bốn ngôn ngữ (Bảng 5). Mức tăng trung bình ước tính là **+28,7 điểm phần trăm** so với baseline.

Table 5: Kết quả Phương pháp 2: Tinh Chỉnh XLM-RoBERTa (`xlm-roberta-base`)

Ngôn ngữ	Accuracy	Macro-F1	N test	Δ Acc
EN	95,4%	0,954	800	+31,3 pp
VI	70,3%	0,702	797	+19,6 pp
ZH	71,5%	0,712	800	+23,9 pp
AR	88,3%	0,882	800	+40,0 pp
Tổng	81,4%	0,814	3.197	+28,7 pp

Tiếng Ả Rập đạt mức tăng lớn nhất (+40,0 pp), từ trạng thái “phân loại sai hệ thống” lên 88,3% — cho thấy XLM-RoBERTa đã học được các đặc trưng




Fig. 1: Đường cong ROC — Baseline (roberta-base-openai-detector). Chỉ EN đạt AUC khả dụng (>0.6); AR, VI, ZH gần như ngẫu nhiên.

hình thái của tiếng Ả Rập một cách hiệu quả. Tiếng Việt và tiếng Trung đạt khoảng 70–72%, thấp hơn đáng kể so với EN và AR, phản ánh độ khó nội tại: Teencode trong tiếng Việt và văn bản Weibo cực ngắn (15–30 ký tự) trong tiếng Trung. Hình 2 hiển thị đường cong ROC sau tinh chỉnh.

5.3 Kết Quả Phát Hiện Dựa Trên Perplexity

Bảng 6 và Hình 3 trình bày kết quả phương pháp PPL. EN (AUC = 0,754) và AR (AUC = 0,778) đạt hiệu năng khá tốt, trong khi VI (AUC = 0,538) và ZH (AUC = 0,534) gần như ngẫu nhiên.

Table 6: Kết quả Phương pháp 3: Perplexity Zero-Shot (Qwen2.5-1.5B)

Ngôn ngữ	AUC-ROC	PPL _{Human}	PPL _{Machine}	Tỉ lệ Đánh giá
EN	0,754	1.193,6	187,1	6,4× Tốt
AR	0,778	260,7	76,7	3,4× Tốt
VI	0,538	1.210,4	796,0	1,5× Yếu
ZH	0,534	221,5	207,9	1,07× Ngẫu nhiên




Fig. 2: Đường cong ROC — XLM-RoBERTa sau tinh chỉnh. EN và AR đạt AUC gần hoàn hảo (>0.95); VI và ZH cải thiện đáng kể so với baseline.

Hiệu năng kém của VI và ZH được lý giải qua tỉ lệ PPL: ZH chỉ đạt $1,07\times$ — con người và máy hầu như không phân biệt được qua PPL — do bài đăng Weibo cực ngắn khiến cả hai lớp có entropy tương đương nhau. VI đạt $1,5\times$ nhưng chưa đủ lớn để phân tách tốt, do Teencode làm tăng PPL đồng đều cho cả hai lớp.

5.4 Kết Quả Học Chuyển Giao (Transfer Learning)

Bảng 7 trình bày kết quả của bốn thí nghiệm *leave-one-language-out*. Hiệu năng trung bình chỉ đạt **54,9% accuracy** và **0,543 F1**, gần với mức ngẫu nhiên.

Table 7: Kết quả học chuyển giao (xlm-roberta-base, leave-one-language-out)

Ngôn ngữ	Ngôn ngữ huấn luyện	Acc	F1	ROC-AUC
EN	VI, ZH, AR	0,545	0,683	0,851
VI	EN, ZH, AR	0,531	0,134	0,536
ZH	EN, VI, AR	0,503	0,666	0,512
AR	EN, VI, ZH	0,619	0,691	0,810
Trung bình		0,549	0,543	0,677




Fig. 3: Đường cong ROC của phương pháp PPL (Qwen2.5-1.5B) trên 4 ngôn ngữ. EN và AR có đường cong gần góc trên trái; ZH gần như trùng đường chéo ngẫu nhiên.

Kết quả cho thấy ba hiện tượng đáng chú ý:

1. **Tiếng Việt thất bại hoàn toàn** ($F1 = 0,134$, $\text{recall} = 0,076$): Mô hình dự đoán gần như toàn bộ là “human”, cho thấy đặc trưng MGT tiếng Việt (Teencode, cấu trúc câu không chính thức) không thể học được từ các ngôn ngữ khác.
2. **Tiếng Trung bị thoái hóa** ($\text{Acc} = 50,3\%$): Mô hình thiên về nhãn “machine” (395/400 human bị phân loại sai), dẫn đến recall cao giả tạo (0,99) nhưng precision ngang tung đồng (0,501).
3. **EN và AR được hưởng lợi một phần**: AR đạt kết quả tốt nhất ($\text{Acc} = 61,9\%$, $\text{AUC} = 0,81$). EN đạt recall 0,98 nhưng precision chỉ 0,524 — thiên lệch về nhãn “machine”.

5.5 So Sánh Tổng Hợp Bốn Phương Pháp

Bảng 8 tổng hợp hiệu năng của bốn phương pháp.

XLM-RoBERTa tinh chỉnh là phương pháp vượt trội nhất trên tất cả ngôn ngữ và tiêu chí. Phương pháp PPL có ưu điểm zero-shot (không cần dữ liệu nhãn) và hiệu quả với EN/AR, nhưng thất bại với VI/ZH. Baseline tiếng Anh không thể dùng được cho bài toán đa ngôn ngữ. Học chuyển giao cho thấy mỗi ngôn ngữ cần dữ liệu huấn luyện riêng — đặc biệt với các ngôn ngữ có đặc thù hình thái như tiếng Việt và tiếng Trung.

Table 8: So sánh tổng hợp bốn phương pháp

Ngôn ngữ	Baseline Acc	XLM-R Acc	PPL AUC	Transfer Acc
EN	64,1%	95,4%	0,754	54,5%
VI	50,7%	70,3%	0,538	53,1%
ZH	47,6%	71,5%	0,534	50,3%
AR	48,3%	88,3%	0,778	61,9%
Khả dụng	Chỉ EN	4 ngôn ngữ	EN + AR	Không

6 Kết Luận và Hướng Phát Triển

Bài báo này trình bày nghiên cứu so sánh hệ thống bốn phương pháp phát hiện văn bản do máy tạo ra (MGT) trên dữ liệu mạng xã hội đa ngôn ngữ gồm bốn ngôn ngữ: EN, VI, ZH, AR. Bốn kết luận chính được rút ra:

1. **Thiên lệch Anh ngữ là nghiêm trọng và nguy hiểm:** Bộ phát hiện tiền huấn luyện chỉ dành cho tiếng Anh (`roberta-base-openai-detector`) đạt dưới mức ngẫu nhiên trên VI, ZH, AR — thậm chí phân loại sai hệ thống với AR ($F1 = 0,336$). Triển khai detector đơn ngôn ngữ cho bài toán đa ngôn ngữ là không thể chấp nhận được.
2. **Tình chính XLM-RoBERTa là giải pháp thực tế tối ưu:** Đạt **81,4% accuracy** trung bình, huấn luyện trong 7,5 phút trên GPU T4 thông thường với chi phí ước tính **\$1,50**. Phương pháp này chứng minh rằng phát hiện MGT đa ngôn ngữ chất lượng cao không đòi hỏi phần cứng A100 đắt tiền.
3. **PPL zero-shot hữu ích có điều kiện:** Phát hiện dựa trên perplexity (Qwen2.5-1.5B) hoạt động tốt khi tỉ lệ PPL giữa hai lớp đủ lớn (EN: $6,4\times$, AR: $3,4\times$), nhưng thất bại với văn bản MXH nhiễu (VI Teencode, ZH Weibo ngắn).
4. **Học chuyển giao liên ngôn ngữ là chưa đủ:** Thử nghiệm leave-one-language-out cho thấy mỗi ngôn ngữ cần dữ liệu huấn luyện riêng. Tiếng Việt đặc biệt khó khăn ($F1 = 0,134$ khi không có dữ liệu VI trong tập huấn luyện), khẳng định tính tất yếu của dữ liệu đa ngôn ngữ trong bài toán MGT trên MXH.

Hướng Phát Triển

Nghiên cứu tiếp theo có thể khai thác các hướng sau:

- **Mô hình cấp ký tự** cho VI và ZH nhằm xử lý đặc tính Teencode và bài đăng siêu ngắn (15–30 ký tự).
- **Data augmentation** với Teencode giả lập để cải thiện khả năng tổng quát hóa trên VI.
- **Mô hình lớn hơn với quantization:** thử nghiệm XLM-R large (559M) hoặc mGPT với INT8/INT4 quantization trên T4.

- **Mở rộng ngôn ngữ:** Thêm tiếng Nhật, Hàn, Hindi — các ngôn ngữ MXH lớn chưa được nghiên cứu kỹ trong bài toán MGT.
- **Phát hiện cấp đặc trưng ngôn ngữ học:** kết hợp PPL với đặc trưng cú pháp và ngữ nghĩa để vượt qua giới hạn của phương pháp thuần PPL.

Mã nguồn, bộ dữ liệu và pipeline thực nghiệm sẽ được công khai để thúc đẩy nghiên cứu tái lập và mở rộng.

References

1. Al-Omari, H., Abdullah, M., Shaikh, S.: Arabic jordanian general tweets (AJGT) corpus for sentiment analysis. *IEEE Access* **10**, 3655–3664 (2022)
2. Brown, T.B., et al.: Language models are few-shot learners. *Advances in Neural Information Processing Systems (NeurIPS)* **33**, 1877–1901 (2020)
3. Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., Stoyanov, V.: Unsupervised cross-lingual representation learning at scale pp. 8440–8451 (2020)
4. Equi, M., et al.: Perplexity-based detection of machine-generated text: A systematic study (2024)
5. Guo, B., Zhang, X., Wang, Z., Jiang, M., Nie, J., Ding, Y., Yue, J., Wu, Y.: How close is ChatGPT to human experts? comparison corpus, evaluation, and detection (2023)
6. Hans, A., Schwarzschild, A., Cherepanova, V., Kazemi, H., Saha, A., Goldblum, M., Geiping, J., Goldstein, T.: Spotting LLMs with binoculars: Zero-shot detection of machine-generated text. In: *Proceedings of the 41st International Conference on Machine Learning (ICML)* (2024)
7. Mitchell, E., Lee, Y., Khazatsky, A., Manning, C.D., Finn, C.: DetectGPT: Zero-shot machine-generated text detection using probability curvature. In: *Proceedings of the 40th International Conference on Machine Learning (ICML)*. pp. 24950–24962 (2023)
8. Nguyen, T.T.T., et al.: VSmeC: A dataset for vietnamese social media emotion classification. In: *Proceedings of the International Conference on Asian Language Processing (IALP)* (2023)
9. Qwen Team: Qwen2.5: A party of foundation models (2024)
10. Solaiman, I., Brundage, M., Clark, J., Askill, A., Herbert-Voss, A., Wu, J., Radford, A., Wang, J.: Release strategies and the social impacts of language models (2019)
11. Touvron, H., et al.: LLaMA: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971* (2023)
12. Zellers, R., Holtzman, A., Rashkin, H., Bisk, Y., Farhadi, A., Roesner, F., Choi, Y.: Defending against neural fake news. In: *Advances in Neural Information Processing Systems (NeurIPS)*. vol. 32 (2019)