



TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Phát hiện văn bản do máy tạo trên mạng xã hội

Nghiên cứu AI Detection dưới ràng buộc tài nguyên

Người thực hiện: Hoàng Nguyễn Anh Khoa

Nhóm 21

Giảng viên hướng dẫn: Lưu Thanh Sơn

Khoa Khoa học và Kỹ thuật Thông tin



Động lực và Vấn đề Nghiên cứu

Sự phát triển nhanh chóng của các mô hình ngôn ngữ lớn (LLM) đặt ra yêu cầu cấp thiết đối với bài toán phát hiện văn bản do máy tạo ra (MGT) trong bối cảnh đa ngôn ngữ trên mạng xã hội.

- Các LLM hiện đại (GPT-4, LLaMA, Qwen) có khả năng sinh văn bản gần như không thể phân biệt với văn bản do con người viết.
- Phần lớn các bộ phát hiện hiện có được huấn luyện và đánh giá chủ yếu trên tiếng Anh; hiệu suất suy giảm đáng kể khi áp dụng cho các ngôn ngữ khác.
- Nhiều phương pháp tiên tiến đòi hỏi GPU cấu hình cao (A100, 40–80 GB VRAM), gây khó khăn tiếp cận đối với các nhóm nghiên cứu có nguồn lực hạn chế.
- Văn bản mạng xã hội có đặc điểm ngắn, nhiều và pha trộn mã ngôn ngữ, làm tăng độ khó của bài toán phát hiện so với văn bản trang trọng.



Công trình Liên quan và Khoảng trống Nghiên cứu

Các nghiên cứu trước đây tập trung chủ yếu vào tiếng Anh; bài toán phát hiện đa ngôn ngữ vẫn chưa được khai thác đầy đủ.

- ▶ Bộ phát hiện GPT-2 (Solaiman và cộng sự, 2019): giới hạn ở tiếng Anh, tiếp cận zero-shot.
- ▶ DetectGPT (Mitchell và cộng sự, 2023): yêu cầu quyền truy cập white-box vào mô hình nguồn.
- ▶ MultiSocial (nghiên cứu gốc): bộ dữ liệu đa ngôn ngữ quy mô lớn đầu tiên, gồm 11 ngôn ngữ.
- ▶ Nghiên cứu này: nghiên cứu tái lập trên 4 ngôn ngữ, thực hiện trong điều kiện tài nguyên hạn chế.



Câu hỏi Nghiên cứu và Đóng góp

Nghiên cứu giải quyết ba câu hỏi nghiên cứu thông qua bốn phương pháp thực nghiệm.

RQ1: Các bộ phát hiện được huấn luyện trước trên tiếng Anh có khả năng tổng quát hóa sang các ngôn ngữ khác hay không?

RQ2: Việc tinh chỉnh (fine-tuning) mô hình chuyển đổi đa ngôn ngữ có cải thiện hiệu suất phát hiện hay không?

RQ3: Phương pháp phát hiện zero-shot dựa trên perplexity có hiệu quả nhất quán giữa các ngôn ngữ hay không?

RQ4: Học chuyển tiếp (huấn luyện trên ba ngôn ngữ, kiểm tra trên ngôn ngữ còn lại) có hỗ trợ hiệu quả cho bài toán phát hiện đa ngôn ngữ hay không?

Đóng góp: Bộ dữ liệu MultiSocial-4L, so sánh có hệ thống giữa bốn phương pháp, và một đường ống xử lý có thể triển khai trên Google Colab.



Xây dựng Bộ dữ liệu — MultiSocial-4L

Nghiên cứu xây dựng một bộ dữ liệu cân bằng gồm bốn ngôn ngữ với 15.986 bài đăng mạng xã hội.

- **Bốn ngôn ngữ:** Tiếng Anh (EN), Tiếng Việt (VI), Tiếng Trung (ZH), Tiếng Ả Rập (AR).
- Khoảng **4.000 mẫu** cho mỗi ngôn ngữ, cân bằng giữa nhân người viết và máy sinh.
- Văn bản do máy tạo ra được sinh bởi các LLM hiện đại thuộc họ GPT.
- Văn bản do con người viết được thu thập từ các kho ngữ liệu mạng xã hội thực tế.
- **Tỷ lệ chia:** 12.789 huấn luyện / 3.197 kiểm tra (80%/20%).
- Bộ dữ liệu bao gồm siêu dữ liệu: độ dài văn bản, nguồn thu thập, chỉ số nhiễu.



Thiết lập Thực nghiệm và Ràng buộc Phần cứng

Toàn bộ thực nghiệm được thực hiện trên một GPU Google Colab T4 (16 GB VRAM).

- ▶ **Phần cứng:** Gói miễn phí của Google Colab, GPU NVIDIA T4 (16 GB); tổng chi phí API khoảng 1,50 USD.
- ▶ **Khả năng tái lập:** Sử dụng SEED = 42 xuyên suốt toàn bộ thực nghiệm, với cách chia tập dữ liệu cố định.
- ▶ Bốn phương pháp được đánh giá trên cùng một tập kiểm tra nhằm đảm bảo tính công bằng trong so sánh.
- ▶ Kích thước batch được điều chỉnh phù hợp với dung lượng VRAM, kèm chiến lược xử lý khi xảy ra lỗi tràn bộ nhớ (OOM).
- ▶ **Chỉ số đánh giá:** Accuracy, Precision, Recall, F1-macro, ROC-AUC.



Phương pháp 1 — Bộ phát hiện Huấn luyện trước

Đường cơ sở RoBERTa-OpenAI

Phương pháp zero-shot sử dụng mô hình roberta-base-openai-detector đạt hiệu suất gần với mức ngẫu nhiên trên các ngôn ngữ ngoài tiếng Anh.

Kết quả tổng thể

- ▶ Acc = 52,7%, F1 = 48,0%, AUC = 59,0%
- ▶ Tiếng Anh: Acc = 64,1%, AUC = 73,8% (hiệu suất cao nhất)
- ▶ Tiếng Việt, Trung, Ả Rập: gần mức ngẫu nhiên (~50%)

Kết quả củng cố giả thuyết: bộ phát hiện chỉ huấn luyện trên tiếng Anh không hiệu quả với các ngôn ngữ khác.



Phương pháp 2 — Tinh chỉnh XLM-RoBERTa

Việc tinh chỉnh XLM-RoBERTa trên dữ liệu đa ngôn ngữ cải thiện đáng kể hiệu suất phát hiện trên toàn bộ bốn ngôn ngữ.

- **Mô hình:** xlm-roberta-base (278 triệu tham số, hỗ trợ 100 ngôn ngữ).
- **Cấu hình:** 3 epoch, learning rate = $2e-5$, batch size = 16, sử dụng fp16.

Kết quả

- **Tổng thể:** Acc = 81,4%, F1 = 81,4%, AUC = 91,4%
- **EN:** 95,4% | **AR:** 88,3% | **ZH:** 71,5% | **VI:** 70,3%
- **Cải thiện:** +28,7 điểm phần trăm so với đường cơ sở



Phương pháp 3 — Zero-shot dựa trên Perplexity

Phương pháp phát hiện dựa trên perplexity, sử dụng Qwen2.5-1.5B, cho kết quả tốt ở một số ngôn ngữ nhưng không hiệu quả ở các ngôn ngữ còn lại.

- **Mô hình tham chiếu:** Qwen2.5-1.5B
- Điểm số phát hiện được tính bằng perplexity âm (PPL thấp hơn → khả năng cao hơn là văn bản do máy tạo ra)
- **AUC tổng thể:** 65,3%

Kết quả theo ngôn ngữ

- **EN:** AUC = 75,4% (tỷ lệ PPL = 0,16)
- **AR:** AUC = 77,8% (tỷ lệ PPL = 0,29)
- **VI:** AUC = 53,8% — gần mức ngẫu nhiên
- **ZH:** AUC = 53,4% — gần mức ngẫu nhiên

Phương pháp hiệu quả khi mô hình ngôn ngữ tham chiếu có độ phù tốt đối với ngôn ngữ mục tiêu.



Phương pháp 4 — Học Chuyển tiếp (Bỏ-một-ngôn-ngữ)

Việc huấn luyện trên ba ngôn ngữ và kiểm tra trên ngôn ngữ còn lại cho kết quả chuyển tiếp không đồng đều giữa các ngôn ngữ.

- **Thiết kế:** Bốn cấu hình, mỗi cấu hình loại một ngôn ngữ khỏi tập huấn luyện
- **Mô hình:** XLM-RoBERTa, 5 epoch, early stopping với patience = 2

Kết quả chuyển tiếp

- **Tốt nhất:** Huấn luyện EN+VI+ZH, kiểm tra AR → F1 = 69,1%, AUC = 81,0%
- **Kém nhất:** Huấn luyện EN+ZH+AR, kiểm tra VI → F1 = 13,4% (dự đoán theo lớp đa số)
- **Accuracy trung bình:** 54,9% — khả năng chuyển tiếp còn hạn chế



Tổng hợp và So sánh Kết quả

XLM-RoBERTa tinh chỉnh là phương pháp cho hiệu suất tốt nhất; không có phương pháp đơn lẻ nào đạt hiệu quả đồng đều trên tất cả các ngôn ngữ.

Phương pháp	F1 Tổng thể	EN	AR	ZH	VI
Đường cơ sở	48,0%	64,1%	~50%	~50%	~50%
Tinh chỉnh XLM-R	81,4%	95,4%	88,2%	71,5%	70,3%
Perplexity	65,3%	75,4%	77,8%	53,4%	53,8%
Học chuyển tiếp	54,3%	~60%	69,1%	~50%	13,4%

Tinh chỉnh là điều kiện cần thiết để đạt được khả năng phát hiện đa ngôn ngữ đáng tin cậy.



Phát hiện Chính và Hạn chế của Nghiên cứu

Nghiên cứu tái lập xác nhận các phát hiện cốt lõi của công trình gốc, đồng thời làm rõ những hạn chế thực tế khi triển khai ở quy mô nhỏ.

Kết quả tái lập được

- Khoảng cách hiệu suất phát hiện đa ngôn ngữ
- Lợi ích của việc tinh chỉnh mô hình đa ngôn ngữ
- Hiệu quả không đồng đều của phương pháp dựa trên perplexity

Hạn chế

- Bộ dữ liệu nhỏ hơn (16K so với 200K mẫu trong nghiên cứu gốc)
- Chỉ sử dụng một bộ sinh LLM cho mỗi ngôn ngữ
- GPU T4 giới hạn kích thước mô hình có thể sử dụng
- Chưa kiểm tra độ bền đối nghịch (adversarial robustness)



Kết luận và Hướng phát triển

Mô hình chuyển đổi đa ngôn ngữ được tinh chỉnh là phương pháp khả thi nhất cho bài toán phát hiện MGT trong điều kiện tài nguyên hạn chế.

Kết luận chính

- XLM-RoBERTa tinh chỉnh đạt **F1 tổng thể 81,4%** trên bốn ngôn ngữ
- Bộ phát hiện huấn luyện trước chỉ trên tiếng Anh không đáp ứng được yêu cầu đa ngôn ngữ
- Phương pháp dựa trên perplexity phụ thuộc nhiều vào đặc điểm ngôn ngữ, chưa đủ ổn định

Hướng phát triển

- Huấn luyện đối nghịch và mở rộng bộ dữ liệu
- Bổ sung nhiều bộ sinh LLM khác nhau
- Mở rộng sang văn bản pha trộn mã ngôn ngữ
- Xây dựng phương pháp kết hợp (ensemble)

Hỏi và Đáp

Cảm ơn sự theo dõi của quý thầy cô và sinh viên.

Hoàng Nguyễn Anh Khoa

Nhóm 21

Giảng viên hướng dẫn: Lưu Thanh Sơn

Khoa Khoa học và Kỹ thuật Thông tin